ONBOARDING RAG · MVP PLAN

온보딩 RAG 설계 및 구현 계획

AI팀에서 이미 합의한 기술 방향, 앞으로 함께 결정할 항목, 직접 코딩으로 완성할 구현 단계를 하나의 실행 문서로 정리했다.

01 정해진 것

현재 합의된 목표·모델·문서 처리·응답 구조

02 정해야 할 것

구현 전에 팀이 선택하고 기록해야 할 계약

03 앞으로 구현

환경 구성부터 검증과 문서화까지의 작업 목록

작성 기준일 2026-11-08 · 개발 방식: AI는 설명·힌트·리뷰, 구현 코드는 개발자가 직접 작성

1 정해진 것

AI팀 내부에서 합의했거나 현재 설계 기준으로 채택한 항목이다.

핵심 MVP 사용자가 질문하면 권한 범위 안에서 관련 회사 문서를 검색하고, 문서에 근거한 답변과 출처를 실시간으로 제공한다.

대분류	세부 항목	현재 정해진 내용	확정 범위
서비스	목표	회사 문서를 검색해 근거와 함께 답하는 온보딩 RAG 서비스	AI팀 내부 확정
서비스	답변 원칙	모델 지식만으로 답하지 않고 검색한 문서를 근거로 답변	AI팀 내부 확정
서비스	출처	답변과 함께 참고한 문서 정보를 반환	AI팀 내부 확정
AI 구성	검색 모델	`bge-m3`	현재 선택
AI 구성	답변 모델	`Qwen3 8B`	현재 선택
AI 구성	모델 출처	Hugging Face 공개 모델 사용	현재 선택
AI 구성	모델 실행	Ollama로 로컬 모델 실행	현재 선택
AI 구성	AI 서버	Python + FastAPI	현재 선택
문서 처리	청킹 크기	문서를 800자 단위로 분할	초기 설정 확정
문서 처리	오버랩	앞뒤 문맥 120자 중복	초기 설정 확정
문서 처리	검색 개수	질문과 가까운 문서 조각 Top 5 검색	초기 설정 확정
문서 처리	답변 입력	검색한 5개 조각을 Qwen3 8B에 전달	AI팀 내부 확정
문서 처리	메타데이터	문서명·원문 위치·수정일을 문서 조각과 함께 관리	AI팀 내부 설계
검색 흐름	1단계	사용자 질문을 임베딩으로 변환	AI팀 내부 확정
검색 흐름	2단계	벡터 검색으로 관련 문서 조각 5개 조회	AI팀 내부 확정
검색 흐름	3단계	검색 결과를 기반으로 답변 생성	AI팀 내부 확정
검색 흐름	4단계	답변과 출처 문서 목록 반환	AI팀 내부 확정
저장 범위	AI팀 저장 데이터	문서 조각·임베딩·검색용 메타데이터	AI팀 담당 확정
저장 범위	백엔드 저장 데이터	사용자·권한·대화·완성 답변·참고 문서 목록	역할 구분 설계
저장 범위	DB 분리 원칙	같은 PostgreSQL을 사용해도 백엔드와 AI DB·계정을 분리	AI팀 제안
응답	전송 방식	SSE 실시간 스트리밍	AI팀 내부 확정
응답	이벤트	답변 조각·참고 문서·완료 신호·오류 신호 전송	AI팀 내부 확정
역할	AI팀	문서 인덱싱·임베딩·검색·답변 생성·출처 반환	확정
역할	백엔드	사용자 인증·권한 확인·대화 및 완성 답변 저장	역할 구분 설계
검증	평가 방향	실제 회사 질문 50개로 검색 정확도와 응답 속도 확인	방향 확정
일정	4주 계획	1주 설계·모델 테스트, 2~3주 구현·연동, 4주 통합 테스트	계획 확정

2 정해야 할 것

코드를 본격적으로 작성하기 전에 팀이 선택하고 문서로 남겨야 하는 항목이다.

카테고리	결정 항목	결정해야 하는 내용	현재 상태
Git 컨벤션	브랜치·커밋·MR	기본 브랜치, 기능 브랜치 이름, 커밋 형식, 리뷰 인원, 병합 방식	미정
벡터 DB	제품 선택	pgvector·Chroma·FAISS 중 MVP 저장소 확정	미정
문서 처리	지원 형식	PDF·DOCX·Markdown·TXT 중 어떤 형식을 MVP에서 읽을지 선택	미정
문서 처리	저장 위치	공유 폴더·오브젝트 스토리지·Git 저장소 중 원문 위치 확정	미정
문서 처리	갱신 정책	신규·수정·삭제 문서를 언제 감지하고 재임베딩할지 결정	미정
저장 구조	DB·계정 분리	백엔드 DB와 AI DB의 이름, 계정, 최소 권한 확정	제안만 있음
API 계약	요청 JSON	질문, 사용자, 권한 범위, 이전 대화 필드와 검증 규칙	미정
API 계약	SSE 이벤트	답변·출처·완료·오류 이벤트 이름과 payload 형식	방향만 확정
권한	범위 이름	전체 공개·개발부·AI팀 등 권한 식별자와 문서 매핑 규칙	미정
오류	실패 기준	시간 초과, 문서 없음, 모델 오류, 잘못된 요청의 코드와 메시지	미정
검증	정답 기준	50개 질문별 정답 문서와 필수 답변 요소 작성 방식	미정
검증	합격 기준	Top 5 적중률, 근거 일치율, 환각 허용치, 응답시간 목표	미정
프론트	출처 카드	문서명·관련 문장·원문 위치를 어떤 형태로 표시할지 결정	미정
프론트	오류 화면	실패 이유, 재시도, 담당자 문의를 어떻게 보여줄지 결정	미정
완료 기준	MVP Definition of Done	필수 사용자 흐름, 테스트, 문서화, 시연 조건을 체크리스트로 확정	기능 범위만 확정

권장 결정 순서 Git 컨벤션 → MVP 완료 기준 → 벡터 DB와 문서 형식 → 권한 구조 → API·SSE 계약 → 검증 합격 기준 → 화면 표현

3 앞으로 구현

AI에게 전체 구현을 맡기지 않고, 설명·의사코드·테스트·리뷰를 받아 개발자가 직접 작성한다.

완료선 아래 작업을 완료 기준대로 끝내면 질문 → 권한 필터 → 문서 검색 → 답변 생성 → 출처 표시가 가능한 검증된 MVP가 된다.

단계	대분류	세부 작업	직접 구현할 내용	완료 기준
1	협업 준비	저장소 구조 확인	저장소를 clone하고 폴더와 실행 구조를 직접 확인	팀원 모두 동일하게 실행
1	협업 준비	Git 컨벤션 적용	브랜치 생성, commit·push·MR을 직접 수행	MR 하나 정상 병합
2	개발환경	Python 환경	가상환경 생성과 패키지 설치	FastAPI 서버 실행
2	개발환경	기본 API	`/health` 엔드포인트 직접 작성	200 응답 확인
2	개발환경	Ollama 연결	Qwen3 8B 호출 코드 작성	질문 응답 출력
2	개발환경	PostgreSQL 연결	DB 연결 설정과 조회 테스트 작성	서버에서 조회 성공
2	개발환경	벡터 저장소	선택한 저장소의 스키마와 연결 작성	벡터 저장·조회 성공
3	문서 인덱싱	문서 읽기	선택한 문서 형식을 읽는 코드 작성	원문 출력 확인
3	문서 인덱싱	청킹	800자·overlap 120자 분할 함수 작성	청크 경계 검증
3	문서 인덱싱	임베딩	bge-m3 호출 코드 작성	청크 벡터 생성
3	문서 인덱싱	저장	청크·벡터·메타데이터 저장	DB 데이터 확인
4	문서 검색	질문 임베딩	질문을 bge-m3 벡터로 변환	질문 벡터 생성
4	문서 검색	유사도 검색	유사 문서 Top 5 조회 구현	관련 문서 5개 출력
4	문서 검색	권한 필터	허용 문서 범위를 검색 조건에 적용	권한 밖 문서 차단
5	답변 생성	프롬프트	질문과 검색 문서를 프롬프트로 조립	최종 입력 확인
5	답변 생성	Qwen3 호출	Ollama 답변 생성 코드 작성	근거 기반 답변 생성
5	답변 생성	환각 제한	근거가 없으면 모른다고 답하는 규칙 적용	문서 밖 추측 차단
5	답변 생성	출처 연결	사용 문서명과 위치를 답변에 연결	답변과 출처 출력
6	API	질문 API	질문·권한·이전 대화를 받는 API 작성	정상·오류 요청 처리
6	API	SSE 스트리밍	답변 조각을 순서대로 전송	실시간 표시 확인
6	API	완료 이벤트	완성 답변과 출처를 완료 이벤트로 전달	완료 신호 수신
6	API	오류 이벤트	모델·문서·요청 오류를 구분해 전송	오류별 메시지 확인
7	연동	백엔드 연동	인증·권한 정보를 AI API에 전달	로그인 질문 성공
7	연동	프론트 연동	질문·스트리밍·출처를 화면과 연결	전체 흐름 동작
7	연동	대화 저장	완성 답변과 출처를 백엔드에 저장	새로고침 후 복원
8	검증	평가 질문	실제 질문 50개와 정답 문서 작성	평가 데이터 완성
8	검증	검색 평가	정답 문서의 Top 5 포함 여부 측정	검색 지표 산출
8	검증	답변 평가	근거 일치·환각·출처 정확성 평가	질문별 결과 기록
8	검증	성능 평가	검색·첫 답변·전체 답변 시간 측정	평균·최대 시간 산출
9	마무리	통합 테스트	질문부터 답변·출처 저장까지 검증	전체 흐름 성공
9	마무리	문서화	설치법·구조·실행법·평가 결과 작성	문서만 보고 실행

AI에게 맡길 것

개념 설명, 입출력 정의, 의사코드, 테스트 사례, 작성한 코드 리뷰

직접 할 것

코드 입력, 명령 실행, 오류 원인 추측, 테스트 결과 해석, 동작 설명

한 번의 작업 단위

작은 기능 하나를 이해 → 의사코드 → 구현 → 테스트 → 설명 순서로 종료

첫 번째 구현

FastAPI `/health` → 문서 하나 읽기 → 800자 청킹 결과 출력